# Hadoop与Spark集群配置总体流程及踩坑记录

作者: lalalapotter

伪分布式配了好多次,但还是首次在多台服务器上配置hadoop和spark,总的来说还是逼不得已,课程PJ的资源太少,只能自己摸索配置了。加油!

## 环境设置

python2.7

pyspark 2.2.0

**IDK1.8** 

hadoop 2.8.3

Scala 2.12

spark 2.2.0

## 服务器地址:

10.88.3.55

10.88.3.81

10.88.3.82

注意:配置文件中原本没有的,可以利用template文件复制之后重命名,再做修改

## Hadoop集群配置

首先检查三个服务器之间是否可以ping的通,已检查。

### 安装JDK

使用了服务器自带的openJDK,此处不知道会不会产生问题? (验证后发现自带openJDK这个比较轻量级的包还是不能满足我们的需要,因此重新下载安装JDK1.8)

只需下载安装包(binary),解压之后放到/opt文件夹下,并重命名为(jdk)

ps: 这里也可以利用软连接

ps: 本人使用连接<u>http://www.oracle.com/technetwork/java/javase/downloads/jdk8-downloads-2133151.html</u>, 下载了这个安装包: jdk-8u171-linux-x64.tar.gz

修改/etc/profile,添加

```
export JAVA_HOME=/opt/jdk
export JRE_HOME=$JAVA_HOME/jre
export CLASSPATH=.:$JAVA_HOME/lib
export PATH=$PATH:$JAVA_HOME/bin
```

不要忘了source /etc/profile

java -version来测试

### 安装hadoop

直接下载hadoop2.8.3 binary包后,解压,放到/opt中,重命名为hadoop

下载地址: http://hadoop.apache.org/releases.html

修改/etc/profile,添加

```
export HADOOP_HOME=/opt/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
```

不要忘了source /etc/profile

hadoop version来测试

### 配置hadoop

hadoop-env.sh

```
export JAVA_HOME=${JAVA_HOME}
#改成:
export JAVA_HOME=/opt/jdk
```

core-site.xml

其中mip为主机ip: 10.88.3.55

hdfs-site.xml

其中dfs.datanode.data.dir这一个在实际问题中在主节点用了(fs.datanode.data.dir),虽然讲道理dfs也是可以的,但是貌似在实际中有一点问题

• mapred-site.xml

此处,如果遇上中文乱码,服务器可能存在编码问题,可以删去,否则可以修改/etc/environment文件,加入

```
LC_CTYPE=zh_CN.UTF-8

LC_ALL=zh_CN.UTF-8

LANG=zh_CN.UTF-8
```

再重启服务器或者重启语言的配置就行了

yarn-site.xml

此处mip也是主节点ip: 10.88.3.55(当然也可以加上用户名)

● 创建上面配置的目录

```
sudo mkdir -p /data/hadoop/hdfs/nn
sudo mkdir -p /data/hadoop/hdfs/dn
sudo mkdir -p /data/hadoop/hdfs/snn
sudo mkdir -p /data/hadoop/yarn/nm
```

在所有结点都同样配置之后,可以启动hadoop集群:

# HDFS集群的启动/关闭

- ▶ 启动/关闭名字节点: hadoop-daemon.sh start/stop namenode
- ▶ 启动/关闭第二名字节点: hadoop-daemon.sh start/stop secondarynamenode
- ▶ 启动/关闭数据节点: hadoop-daemon.sh start/stop datanode

# yarn集群的启动/关闭

- ▶ 启动/关闭资源管理器: yarn-daemon.sh start/stop resourcemanager
- ▶ 启动/关闭节点管理器: yarn-daemon.sh start/stop nodemanager

## 启动 / 关闭MR作业日志服务器

- mr-jobhistory-daemon.sh start/stop historyserver
- 名字节点、资源管理器:这是在主节点中启动或关闭的。

数据节点、节点管理器: 这是在从节点中启动或关闭的。

MR作业日志管理器: 这是在主节点中启动或关闭的。

- web端打开: mip:50070 (此处为10.88.3.55)
- 按照命令启动之后,发现在web端,没有datanode,查看datanode的logs,发现:遇到 datanode启动但不能初始化的问题,报错信息:Datanode denied communication with namenode because hostname cannot be resolved

在主节点hdfs-site.xml添加

● 上面的各个操作要是遇到了权限不足的问题,都可以通过下面的语句来加权限

```
sudo chmod -R 777 filename
```

- 配置主从节点之间的免密登录
  - 。 在所有的主从节点中执行

如果以前配置过免密登录的话,建议删除重新建立过,因为我们需要配置的是多台服务器:

```
rm -r ~/.ssh
```

在~/文件下,执行

```
ssh-keygen
```

为了在主节点中生成公钥和私钥,在从从节点生成.ssh目录,这个中间的步骤一直回车就好

。 在主节点中执行

```
scp ~/.ssh/id_rsa.pub 从节点的用户名@从节点ip:~
```

注意:第一次远程连接的话,首先输入yes,然后是从节点密码

。 在所有的从节点中执行

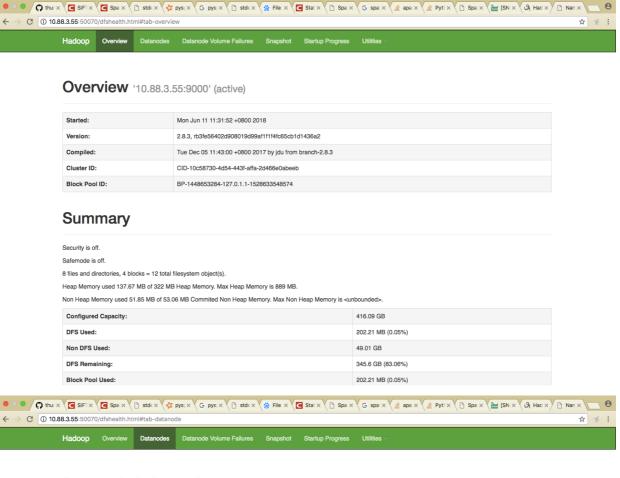
我们把主节点的公钥已经拿到了所有的从节点中,接下来就是:

```
cat id_rsa.pub>>.ssh/authorized_keys
```

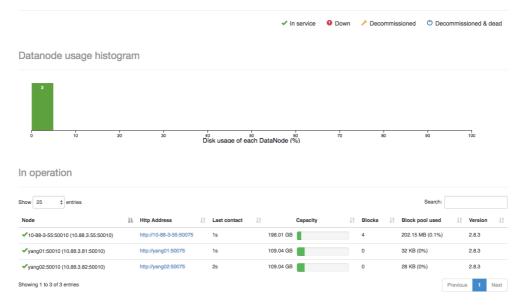
- 实现主节点控制从节点
  - o 在主节点中,在/opt/hadoop/etc/hadoop/slaves中添加相应的从节点用户名@ip(这样,用户名和主节点不一样也可以了)
  - 。 在主节点中

```
cat .ssh/id_rsa.pub >> .ssh/authorized_keys
```

至此,hadoop集群已安装完毕,web端效果图:



### **Datanode Information**



#### 安装scala

下载scala安装包,并解压到/opt文件夹下,重命名为scala2

修改/etc/profile,添加

```
export SCALA_HOME=/opt/scala2
export PATH=$PATH:$SCALA_HOME/bin
```

### 安装spark

下载spark安装包,并解压到/opt文件夹下,重命名为spark2.2

ps: 下载地址为<u>https://www.apache.org/dyn/closer.lua/spark/spark-2.2.0/spark-2.2.0-bin-hadoop2.7.tgz</u>

修改/etc/profile,添加

```
export SPARK_HOME=/opt/spark2.2
export PATH=$SPARK_HOME/bin:$PATH
```

pyspark来测试

测试/opt/spark/bin目录中的spark-shell脚本是否可以运行,来测试scala版本与spark是否配套

### 配置spark

● /opt/spark/conf/spark-env.sh文件配置,添加

```
export JAVA_HOME=/opt/jdk
export SCALA_HOME=/opt/scala2
export HADOOP_HOME=/opt/hadoop

export STANDALONE_SPARK_MASTER_HOST=10.88.3.55
export SPARK_MASTER_IP=$STANDALONE_SPARK_MASTER_HOST

export SPARK_LAUNCH_WITH_SCALA=0
export SPARK_LIBRARY_PATH=${SPARK_HOME}/lib
export SCALA_LIBRARY_PATH=${SPARK_HOME}/lib
export SPARK_MASTER_WEBUI_PORT=18080

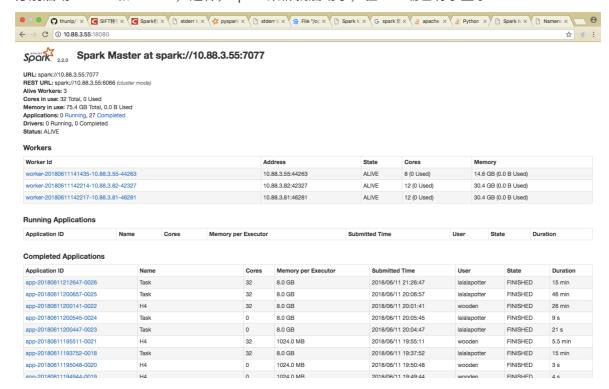
#此处设置端口为18080,由于默认的8080端口很有可能被其他程序使用,所以先让出来

if [ -n "$HADOOP_HOME" ]; then
export
SPARK_LIBRARY_PATH=$SPARK_LIBRARY_PATH:${HADOOP_HOME}/lib/native
fi
```

- 在同一目录下, slaves文件中, 添加三个worker节点的用户名@ip
- 每个节点都这样配置
- 利用10.88.3.55:18080查看sparkUI
- 启动spark要在hadoop启动的前提下
- 遇到spark启动之后,在web端没有显示worker的情况,在主从节点的/opt/spark/sbin目录下利用

```
./start-master.sh -h 10.88.3.55
./start-slave.sh spark://10.88.3.55:7077
```

分别启动master和worker,这样,spark集群就启动了,在web端也有了显示:



• 运行测试程序是遇到以下错误代码:

```
18/06/11 15:52:49 ERROR Executor: Exception in task 5.3 in stage 0.0
org.apache.spark.api.python.PythonException: Traceback (most recent
call last):
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/worker.py", line
    func, profiler, deserializer, serializer = read_command(pickleSer,
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/worker.py", line
55, in read command
    command = serializer. read with length(file)
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/serializers.py",
line 169, in read with length
    return self.loads(obj)
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/serializers.py",
line 454, in loads
    return pickle.loads(obj)
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/cloudpickle.py",
line 784, in _make_skel_func
    closure = _reconstruct_closure(closures) if closures else None
  File "/opt/spark2.2/python/lib/pyspark.zip/pyspark/cloudpickle.py",
line 776, in reconstruct closure
    return tuple([ make cell(v) for v in values])
TypeError: 'int' object is not iterable
```

# 总结

至此,hadoop集群和spark集群的能够正常运行了,果然人还是要逼着自己才能干点事。